K리그 팬 여론과 경기력의 상관 구조 분석 – 유튜브 댓글 데이터를 활용한 정량 연구

요약

본 연구는 2024시즌 K리그 일부 구단을 대상으로, 온라인 팬 댓글의 감정적 반응이 실제 경기력 지표와 어떤 연관을 보이는지 탐색적으로 분석하였다. 이를 위해 유튜브 경기 하이라이트 댓글 중 일정 기준(30자 이상)을 충족하는 데이터를 수집하고 기본적인 정제 과정을 거쳤다. 이후 BERTopic으로 주요 감정·의견 범주를 분류하였고, 팀 경기력 자료는 PCA를 적용해 공격 전개, 득점 효율, 수비 안정성의 세 축으로 단순화하였다. 팀별 감정 토픽과 PCA 성분 간의 상관관계를 검토한 결과, 구단별 팬 여론은 경기력의 변화와 일정 부분 연결되지만, 그 강도·방향·일관성은 팀 상황에 따라 크게 달랐다. 특히 하위권 팀에서는 경기력 개선이 여론 개선으로 이어지지 않는 등 단순한 선형 관계로 설명되지 않는 양상이 확인되었다. 이러한 결과는 팬 감정 데이터가 경기력의 직접적 지표라기보다는, 팀 성적·전술적 맥락·시즌 내 기대 수준이 복합적으로 작용한 결과임을 시사한다.

1. 서론

최근 스포츠 분야에서 경기력 데이터를 활용한 정량 분석은 기술 발달과 함께 더욱 활발하게 이루어지고 있다. 특히 팀 퍼포먼스와 팬 반응 간의 상호작용을 해석하려는 시도는 단순한 승패 예측을 넘어, 팬 커뮤니케이션 전략, 경기력 평가, 브랜드 충성도 관리 등 다양한 실무 영역에 영향을 미치면서 학문적으로도 중요한 주제로 부상하고 있다. 축구는 팀 간 상호작용성이 높고 경기 내·외부 요인이 복합적으로 작용하는 종목인 만큼, 경기력과 팬 감정의 변화를 정량적으로 분석할 필요성이 꾸준히 제기되고 있다.

국내외에서도 팬 여론과 경기 맥락의 관계를 규명하려는 다양한 연구가 이루어져 왔다. Yu & Wang(2015)은 2014년 브라질 월드컵 기간 미국 축구 팬의 트위터 데이터를 분석하여 득점 시 긍정 감정이 크게 증가하고, 실점 시 분노·슬픔 등 부정 감정이 강화되는 양상을 확인하였다. 또한 Schumaker & Jarmoszko(2016)는 EPL 구단 관련 트윗의 감성 점수를 활용하여 경기 승패뿐 아니라 득점 격차까지 예측 가능한 모델을 제시하며, 팬 감정이 경기력 예측의 유효한 지표가 될 수 있음을 실증적으로 보여주었다.

한편 최근에는 자연어처리 기반 기법을 활용해 스포츠 팬 데이터를 정교하게 분석하려는 시도가 증가하고 있다. Moutaouakil et al.(2024)은 축구 선수 관련 소셜미디어 약 16만 건을 수집하여 RoBERTa 기반 감성 분석과 BERTopic 토픽 모델링을 결합함으로써, 온라인 팬 감정 및 주제 구조가 실제 선수 경기력 지표와 유의하게 연동된다는 사실을 밝혀냈다. 국내에서도 강명수(2024)는 손흥민 관련 영국 언론 보도를 텍스트마이닝 기반으로 분석하여, 경기 상황 및 사회적 이슈 변화가 언론 감정과 프레이밍에 즉각적인 영향을 미친다는 점을 제시하는 등, 텍스트 기반 감성 분석을 활용한 연구가 점차 확대되고 있다.

이러한 기존 연구들은 팬 감정의 변화나 경기력의 주요 패턴을 개별적으로 정교하게 분석해 왔으나, 텍스트 기반 팬 감정 데이터와 다차원 경기력 지표를 동시에 결합하여 팀 단위로 구조적 상관성을 탐색한 정량 연구는 여전히 제한적이다. 특히 감정 토픽별 반응, 감정 강도 점

수, 그리고 경기력의 다변량 축(PCA) 간의 연동 구조를 통합적으로 비교하는 분석은 K리그를 대상으로 한 연구에서 거의 이루어지지 않았다.

이에 본 연구는 2024시즌 K리그 일부 구단을 대상으로 경기력 지표(PC1-PC3)와 유튜브 댓글 기반 팬 감정 점수 간의 상관 구조를 실증적으로 분석하고자 한다. 경기력 지표를 PCA로 축약한 뒤, 시즌을 네 구간으로 분할하여 구간별 팬 감정 점수와의 Pearson 상관을 산출함으로써 팀별 감정-경기력 연동 패턴을 비교하였다. 분석 과정에서 단순 상관만으로는 표본 크기 및 팀별 맥락 차이에 따른 해석 한계가 확인되었으며, 이에 따라 회귀 분석·시계열 분석·토픽별 감정 반응 모델링 등 다양한 방법론 적용 가능성도 함께 논의한다.

본 논문의 구성은 다음과 같다. 2장에서는 팬 감정 분석 및 경기력 지표 분석에 사용되는 주요 통계·NLP 기법(PCA, 상관분석, BERTopic, GPT 기반 감정 점수 등)의 이론적 배경을 제시한다. 3장에서는 K리그 경기 기록과 유튜브 댓글 데이터의 수집 및 전처리 방법을 설명하고, 4장에서는 실증 분석 결과와 그 해석을 제시한다. 마지막으로 5장에서는 본 연구의 실무적 시사점과 향후 확장 가능성을 논의한다.

2. 연구 방법론

2.1 Principal Component Analysis (PCA)

본 연구에서는 K-리그 팀들의 경기력 특성을 정량적으로 비교하기 위해, 2024 시즌 공식 경기 기록(Official Match Statistics)을 바탕으로 총 73개의 경기력 변수를 구축하였다. 변수는 슈팅, 패스, 점유율, 전진 전개, 압박·수비 행동 등 공격·전개·수비 전 영역을 포괄하는 고차원 지표로 구성되었다.

각 팀 i의 경기력 벡터는 다음과 같이 정의된다.

$$X_i = (X_{i1}, X_{i2}, \ldots, X_{i73})$$

변수 간 단위 및 분산 차이가 분석 결과에 영향을 미치는 것을 방지하기 위해, 모든 변수는 평균 0, 분산 1을 갖도록 표준화(z-score normalization)하였다.

$$z_{ij} = \frac{X_{ij} - \overline{x_j}}{s_j}$$

표준화된 데이터 행렬을 Z라 할 때, 주성분 분석(PCA)은 다음과 같은 공분산 행렬을 구성한다.

$$S = \frac{1}{n-1} Z^T Z$$

이후 공분산 행렬에 대해 고유값 분해(eigenvalue decomposition)를 수행하여 주성분을 추출하였다.

$$Sv_k = \lambda_k v_k$$

PCA 결과, 상위 3개의 주성분(PC1-PC3)이 전체 분산의 약 70-80%를 설명하여 분석에 사용하였다. 이는 고차원 스포츠 경기력 데이터를 저차원 공간으로 축약하여 주요 패턴을 해석하는 데 충분한 설명력을 제공한다는 기존 연구의 기준과도 부합한다(Jolliffe & Cadima, 2016).

각 주성분의 의미는 고유벡터의 적재값(loadings)을 바탕으로 해석하였으며, 그 결과는 다음과 같다.
- PC1: 공격·패스·빌드업 성향
- PC2: 득점 효율
- PC3: 수비·경합력

이와 같은 접근은 축구 및 팀 스포츠 분석에서 경기력 지표 간 상관 구조를 요약하고, 전술적 특성을 정량화하는 데 널리 활용되는 방법론이다(Barron et al., 2018; Rein & Memmert, 2016).

2.2 BERTopic

본 연구는 K리그 경기 관련 유튜브 댓글을 대상으로 팬 담론의 토픽 구조를 분석하였다. 유튜브 댓글 데이터는 평균 문장 길이가 짧고, 구어체·비표준 표현·감정적 발화가 혼재되어 있으며, 동일 단어의 반복과 맥락 단절이 빈번하게 발생하는 특성을 지닌다. 이러한 데이터 특성은 문서를 단어 빈도 분포로 표현하는 전통적인 Bag-of-Words 기반 토픽 모델이 전제하는 비교적 정규화된 문서 구조와 괴리가 있다. 실제로 LDA와 같은 확률적 토픽 모델은 문서 길이가 극단적으로 짧은 경우 토픽의 안정성과 의미적 응집도가 저하될 수 있음이 지적되어 왔다(Blei et al., 2003; Mimno et al., 2014).

이러한 한계를 보완하기 위해 본 연구는 문장 임베딩과 밀도 기반 군집화를 결합한 BERTopic을 토픽 분석의 주된 방법론으로 채택하였다(Grootendorst, 2022). BERTopic은 사전학습된 문장 임베딩을 활용하여 문장 단위의 의미 정보를 벡터 공간에 투영함으로써, 단어가 직접적으로 일치하지 않더라도 의미적으로 유사한 댓글을 동일한 토픽으로 묶을 수 있다는 장점을 가진다. 이는 짧고 비정형적인 한국어 댓글 간 의미적 유사성을 비교적 안정적으로 반영하는 데 유리하다. 다만 이러한 표현력 역시 임베딩 모델의 사전학습 코퍼스와 도메인 적합성에 영향을 받으며, 모든 구어체 표현을 완전하게 포착한다고 보기는 어렵다.

BERTopic의 군집화 단계에는 HDBSCAN이 사용되었다. HDBSCAN은 군집 수를 사전에 가정하지 않고 데이터의 밀도 구조에 따라 클러스터를 형성하는 방식으로, 잡음이 많은 소셜미디어 텍스트에서 과도한 토픽 분할을 완화하는 데 유리하다(McInnes et al., 2017). 특히 의미적 밀도가 충분히 형성되지 않은 문장은 노이즈로 분류되어 전체 토픽 품질 유지에 기여한다. 반면, 하이퍼파라미터 설정에 따라 결과가 달라질 수 있으며, 데이터 불균형이 클 경우 일부 토픽이 과소 또는 과대 형성될 가능성도 존재한다.

군집화 이후 토픽 해석 단계에서는 class-based TF-IDF(c-TF-IDF)가 적용되었다. c-TF-IDF는 특정 토픽 내에서 상대적으로 자주 등장하지만 전체 코퍼스에서는 덜 등장하는 단어를 강조함으로써 토픽 간 의미적 차이를 명확히 드러내는 데 목적이 있다(Grootendorst, 2022). 본 연구와 같이 감독·선수 비판, 전술·퍼포먼스, 팬 문화 등 의미적 해석이 중요한 맥락에서 이러한 키워드 기반 접근은 토픽의 질적 해석을 지원한다. 다만 한국어의 형태 변이와 고유명사 표기 차이는 일부 토픽에서 키워드 일관성을 저해할 수 있어, 해석 시 보완적 검토가 필요하다.

본 연구는 팀별 팬 담론 구조 비교를 주요 분석 목표로 하므로, 전체 댓글 코퍼스를 단일 모델로 학습한 뒤 각 댓글의 토픽 할당 결과를 팀 단위로 집계하였다. 이를 통해 모든 팀이 동일한 토픽 공간을 공유하도록 함으로써 토픽 의미의 일관성을 유지한 상태에서 팀 간 비교 가능성을 확보하였다. 다만 팀별 댓글 수의 불균형이 전체 임베딩 공간에 영향을 미칠 수 있음을 고려하여, 전처리 단계에서 팀별 표본 분포를 점검하고 중복 제거 및 균형 조정을 병행하였다.

마지막으로 BERTopic에서 제공하는 UMAP 기반 토픽 시각화 및 시간 흐름 분석 기능은 모델 성능 평가 도구가 아닌 탐색적 자료 분석의 보조 수단으로 활용하였다. 차원 축소 기반 시각화는 구조 왜곡 가능성을 내포하므로, 본 연구에서는 정량적 결론 도출보다는 토픽 간 상대적 관계와 전반적 구조를 파악하는 데 한정하여 해석하였다.

2.3 감정분석

본 연구에서는 유튜브 댓글 데이터에 내재된 정성적 감정을 정량적 수치로 변환하기 위하여 대규모 언어모델(Large Language Model, LLM)을 활용한 감정 분석 절차를 적용하였다. 감성분석은 텍스트에 포함된 의견, 태도, 감정의 극성을 자동으로 식별하는 자연어 처리 분야의 핵심 과제로, 소셜미디어 텍스트 분석에서 널리 활용되어 왔다(Liu, 2012). 그러나 유튜브 댓글과 같은 사용자 생성 텍스트는 비표준 표현, 팬덤 특유의 용어, 구어체 및 중첩된 맥락이 빈번하게 나타나며, 이러한 특성은 정적인 감성 사전이나 단어 빈도 기반 접근법이 문장의 실제 의미를 충분히 반영하는 데 한계를 갖는 것으로 지적되어 왔다(Mohammad & Turney, 2013).

이러한 한계를 보완하기 위해 최근 자연어 처리 연구에서는 문맥 이해 능력이 우수한 대규모 언어모델을 감성분석에 활용하려는 시도가 증가하고 있다. LLM은 방대한 텍스트 코퍼스를 기반으로 사전학습되어 문장 수준의 의미 추론 능력을 갖추고 있으며, 별도의 추가 학습 없이도 (zero-shot) 감정 분류 및 극성 판단이 가능하다는 점에서 소셜미디어 텍스트 분석에 적합한 접근법으로 평가되고 있다(Brown et al., 2020; Zhao et al., 2023). 특히 이러한 모델은 단어 자체의 긍·부정 여부뿐 아니라 문맥, 강조 표현, 반어적 표현 등을 종합적으로 고려할 수 있어, 짧고 비정형적인 댓글 데이터에 대한 감정 추론에 상대적으로 유리하다.

본 연구에서는 각 댓글 i에 대하여 감정 라벨 s_i와 연속적 감정 점수 y_i를 다음과 같이 정의하였다.

$$s_i \in \{\text{긍정}, \text{부정}, \text{중립}\}$$
$$y_i \in [-2.0, 2.0]$$

여기서 y_i는 감정의 강도를 반영한 연속형 값으로, -2.0에 가까울수록 강한 부정을, 2.0에 가까울수록 강한 긍정을 의미한다. 감정 표현이 거의 나타나지 않는 경우에 y_i=0으로 정의하였다. 이와 같은 연속현 감정 점수는 이산적 분류 결과보다 감정 감도의 미세한 차이를 반영할 수 있다는 점에서 이후 경기력 지표와의 상관 구조 분석에 적합하다.

댓글에 대한 감정 추론은 OpenAI의 GPT 계열 언어모델을 활용하여 수행하였다. 모델의 응답을 일관된 형식으로 확보하기 위해 규칙 기반 프롬프트를 설계하였으며, 프롬프트에서는 모델에게 “한국어 유튜브 댓글의 감정을 분석하는 어시스턴트” 역할을 부여하고 분석 결과를 반드시 JSON 형식으로만 출력하도록 제한하였다. 출력 형식은 {“sentiment” : “긍정 | 부정 | 중립”, “score”: (감정 강도)}로 고정하여 모델의 자유도를 최소화하였고, 각 댓글 원문은 “문장:{댓글}”의 형태로 입력하여 문맥 기반 감정 추론이 이루어지도록 하였다.

이와 같은 절차를 통해 비정형적인 유튜브 댓글 데이터를 감정라벨과 연속형 점수로 구성된 정략적 감정 데이터로 변환할 수 있었으며, 이는 이후 토픽 모델링 결과 및 PCA 기반 경기력 지표와의 관계를 분석하기 위한 기초 자료로 활용되었다.

2.4 Correlation Analysis

본 연구에서는 토픽별 팬 감정 점수와 팀별 경기력 지표(PCA 기반 주성분) 간의 관계를 파악하기 위해 상관분석을 수행하였다. 팬 감정 데이터는 유튜브 댓글을 기반으로 하며, 경기력 지표는 앞서 도출한 PCA 결과(PC1-PC3)를 사용하였다.

그러나 개별 라운드 단위에서는 댓글 수의 편차가 매우 커, 특정 라운드에서는 분석에 사용할 수 있는 텍스트가 충분히 확보되지 않는 문제가 발생하였다. 특히 토픽 수가 4-5개로 분리되는 경우, 일부 라운드에서는 각 토픽에 대응하는 댓글 수가 극히 적어 상관계수 추정의 분산이 과도하게 커지고, 통계적 신뢰도가 크게 저하되는 한계가 존재하였다. 이는 텍스트 기반 감정 분석 연구에서 빈번히 지적되는 표본 희소성(sparsity) 문제와도 일치한다(Liu, 2012; van Atteveldt et al., 2021).

이러한 한계를 보완하기 위해, 본 연구는 전체 38개 라운드를 4개의 넓은 구간(block)으로 통합하여 분석 단위를 재구성하였다. 각 블록은 다음과 같이 정의된다.

- B1: 1-9R
- B2: 10-18R
- B3: 19-28R
- B4: 29-38R

이와 같은 블록 단위 통합은 표본 수를 안정적으로 확보함으로써 감정 점수의 변동성을 완화하고, 상관계수 추정의 신뢰도를 제고하기 위한 방법이다. 이는 스포츠 데이터 분석 및 사회과학 연구에서 시계열 단위가 짧고 잡음이 큰 경우 흔히 사용되는 접근법이다(James et al., 2013).

토픽별 감정 점수와 경기력 지표 간의 선형적 관계를 측정하기 위해, 본 연구는 피어슨 상관계수(Pearson’s correlation coefficient, r)를 사용하였다. 피어슨 상관계수는 두 연속형 변수 간의 선형적 연관성을 측정하는 대표적인 지표로, 다음과 같이 정의된다.

$$r_{xy} = \frac{cov(x,y)}{\sigma_x \sigma_y}$$

여기서 x는 블록 단위 토픽별 감정 점수, y는 PCA 기반 경기력 지표(PC1, PC2, PC3),

cov(x,y)는 공분산, σ_x, σ_y는 각각의 표준편차를 의미한다.

토픽 T에 대한 전체 상관계수는 다음과 같이 정의된다.

$$r_{T,PC_k} = corr(sentiment_T, PC_k), k \in \{1,2,3\}$$

또한 특정 팀 A의 특정 토픽 T에 대한 상관계수는 다음과 같이 계산된다.

$$r_{A,T,PC_k} = corr(sentiment_{A,T}, PC_k(A)), k \in \{1,2,3\}$$

이를 통해 본 연구는 리그 전반에서의 팬 감정-경기력 관계와 개별 팀 단위에서의 팬 여론과 경기력 간 상관 구조를 동시에 분석하였다. 이러한 다층적 상관 분석 접근은 팬 반응과 실제 경기 성과 간의 정량적 연관성을 탐색하는 데 효과적인 방법으로 선행 연구에서도 활용된 바 있다(Rein & Memmert, 2016; Fernández-Navarro et al., 2018).

3. 연구자료

3.1 경기력 데이터

2024 시즌 K-리그 전 경기의 공식 경기 기록(Official Match Statistics)을 수집하였다. 데이터는 리그의 12개 팀이 치른 정규리그 38라운드(총 228경기)를 대상으로 하며, 각 팀의 경기당 수행 지표를 기반으로 경기력 변수를 구성하였다.

경기력 변수는 총 73개 지표로 이루어져 있으며, 이는 공격(슈팅·유효슈팅·박스 침투 등), 전개(전진 패스, 점유율, 패스 성공률 등), 수비(압박·인터셉트·태클 등)의 세 영역을 포괄한다. 모든 변수는 팀 수준(team-level)의 경기 기록으로 정리되었고, 분석에 적합하도록 경기 단위(team × round) 형태로 구조화하였다.

TABLE 1 Example of Match Performance Statistics for Gwangju FC

R	Competition	H / A	G	A	Sh	SOT	BlkSh	OffT	ShPA	ShOP	FKSh	FK-SOT	FKCr			Offs	CK	TI
													Att	Acc	Acc%			
1	Gwangju vs Seoul	H	2	1	15	6	1	8	9	6	0	0	3	1	33.3	0	8	15
2	Gwangju vs Gangwon	H	4	2	12	6	4	2	9	3	0	0	1	0	0	0	5	20
3	Pohang vs Gwangju	A	0	0	5	2	1	2	3	2	1	0	0	0	0	1	1	11
4	Gwangju vs Daegu	H	1	0	10	4	1	5	9	1	0	0	0	0	0	0	10	21
5	Gwangju vs Incheon	H	2	1	14	4	5	5	9	5	0	0	2	1	50	0	2	19

3.2 대중평가 데이터

본 연구에서는 2024 시즌 K-리그1의 경기력과 대중평가 간의 관계를 분석하기 위하여 총 4개 팀(수원 FC, 울산 HD, 광주 FC, 인천 UTD)의 38라운드 정규리그 경기 영상을 대상으로

유튜브 댓글 데이터를 수집하였다. 데이터 출처는 쿠팡플레이 스포츠 공식 채널에서 제공하는 '2분 하이라이트' 영상이며, 경기 직후 업로드되는 해당 콘텐츠는 팬들의 즉각적 평가가 집중된다는 점에서 분석 자료로 적합하다.

댓글 수집은 YouTube Data API v3를 활용하였으며, 검색 쿼리는 "2024 K리그 {팀명} {라운드}R 2분" 방식으로 구성하였다. 검색 결과에서 공식 채널의 최상단 영상의 videoId를 식별하여 팀-라운드 단위로 매핑하였다. 이후 commentThreads 및 comments 엔드포인트를 이용해 댓글과 대댓글을 모두 수집하였다.

전체 4개 팀 × 38라운드 = 152개 경기 중 누락된 경기는 0건으로 확인되었으며, 수집된 댓글 수의 팀별 요약 통계는 표 2와 같다.

TABLE 2 Summary of collected YouTube comments by team (2024 K-League)

Team	Total comments	Averages comments per match
Gwangju	8,288	218.1
Suwon	6,193	163.0
Ulsan	8,817	232.0
Incheon	7,643	201.1
Total	30,941	814.2

울산과 광주는 경기당 평균 200개 이상의 댓글이 수집되어 팬 참여도가 상대적으로 높았으며, 수원 FC는 평균 163개로 다른 팀에 비해 낮은 편이었다. 전체 152경기에서 총 30,941개의 댓글이 수집되어 텍스트 기반 대중평가 분석에 충분한 데이터 밀도를 확보하였다.

또한 팀-라운드 매핑 결과 누락된 영상이 1건도 존재하지 않아 본 연구의 유튜브 댓글 데이터 구축 과정은 안정적이며 재현성이 높은 것으로 평가된다. 이 데이터는 이후 텍스트 전처리, 토픽 모델링, 감정 분석 및 경기력 지표(PCA)와의 상관 분석에 활용되었다.

4. 연구결과

4.1 PCA 기반 팀 프로파일 분석

PC1·PC2·PC3에 포함된 Top10 지표의 특성을 종합적으로 해석한 결과, 각 주성분이 설명하는 경기 운영의 방향성이 명확하게 구분되어 이를 각각 '점유-빌드업(PC1)', '효율(PC2)', '수비 안정성(PC3)'으로 명명하였다. PC1은 패스 성공, 패스 시도, 전방 패스, 횡패스 등 공 점유와 빌드업 과정에서 나타나는 점유 기반 조율 능력을 구성 지표로 하여 팀의 공세 전개 구조를 가장 잘 설명하는 축으로 나타났다. PC2는 슈팅, PA 내·외 슈팅, 유효 슈팅, 크로스 등 공격의 직접적인 산출물과 효율성을 나타내는 지표로 구성되어, 상대 박스 침투 및 마무리 능력 중심의 공격 효율성을 반영하는 주축으로 해석되었다. PC3는 경합 지상·공중, 태클, 획득 등 수비 및 압박 상황에서의 회수 능력·저항 능력이 다수 포함되어 있어 팀의 수비적 안정성과 압박 회복 역량을 가장 잘 나타내는 주성분으로 도출되었다. 따라서 각 PC의 지표 특성이 설명하는 전술적 의미를 기준으로 '점유-빌드업', '효율', '수비 안정성'이라는 명칭을 부여하는 것이 타당하다고 판단하였다.

TABLE 3 PC1 / PC2 / PC3 Top10 Indicator table

Rank	PC1 (Possession/ build-up)	PC2 (Efficiency)	PC3 (Defensive stability)
Top1	Pass Success	Shooting	Ground Duel
Top2	Pass Attempt	Shot in PA	Duel Success
Top3	Forward Pass	Key Pass	Ball Recovery
Top4	Lateral Pass Success	Ball Recovery	Throw-in
Top5	Lateral Pass Attempt	Cross Success	Aerial Duel
Top6	Short Pass	On-target Shot	Assist
Top7	Central Area Progression	Aerial Duel, Shooting	Throw-in
Top8	Backward Pass	Shot Outside PA	Key Pass
Top9	Backward Pass Attempt	Cross Attempt	Special Point
Top10	Pass Success	Dribble Past	Tackles

PCA를 통해 산출된 각 팀의 PC1·PC2·PC3 점수를 비교한 결과, 전체 K리그 팀 중에서도 울산, 인천, 수원, 광 주가 세 주성분에서 가장 상이하고 독특한 프로파일을 보이는 팀들로 나타나 연구 사례군으로 선정하였다. 특히, 울산과 인천은 당시 리그 1위와 12위로 경기력의 양극단을 대표하며, PCA 값에서도 점유 ·효율 ·수비 안정성의 구조가 뚜렷이 대비되어 전술적 성향을 해석하기에 적합하였다. 수원과 광주는 상위·하위권과는 다른 고유한 특성을 보여, 네 팀 모두가 PCA 공간에서 서로 다른 영역을 형성함으로써 팀별 전술적 특성과 주성 분의 해석을 가장 명확하게 검증할 수 있는 사례군으로 판단되어 최종 선정하였다.

4.2 토픽 모델링 결과

TABLE 4 Topic Distribution of YouTube Comments by Team

No.	Topic	Suwon	Gwangju	Incheon	Ulsan
1	Manager & Player Criticism	9.32%	21.04%	18.12%	24.66%
2	Game Tactics & player Performance	16.44%	27.0%	26.57%	29.02%
3	Scheduling and External Factors	42.74%	25.26%	21.39%	30.36%
4	Fan Culture & Support Atmosphere	26.3%	26.24%	28.07%	13.07%
5	Refereeing & VAR	5.21%	0.45%	5.86%	2.88%

표 4는 네 팀(수원, 광주, 울산, 인천)의 유튜브 댓글에서 추출된 다섯 개 토픽의 비중을 비교한 결과를 제시한다. 분석 결과, 팬 여론의 관심 구조는 팀별로 뚜렷하게 상이한 패턴을 보였다.

먼저 수원은 Topic 3(42.74%)이 가장 높은 비중을 차지하여, 팀 성과 자체보다는 리그 일정, 외부 요인, 운영 환경과 관련된 이슈에 높은 민감도를 보였다. 이는 Topic 2(16.44%)나 Topic 1(9.32%)보다 크게 높은 수치로, 수원 팬덤이 시즌 내 불리한 조건·행정적 요인 등을

핵심 불만 요인으로 인식했음을 시사한다.

반면 광주는 Topic 2(27.0%)와 Topic 1(21.04%)가 상대적으로 높은 비중을 보였으며, Topic 5 관련 언급은 0.45%로 전체 팀 중 가장 낮았다. 이는 광주 팬덤이 판정 논란보다는 경기 내용, 전술적 완성도, 선수·감독의 역할과 책임 등 내부 요인에 집중하는 경향을 나타낸다.

인천은 Topic 4(28.07%)가 가장 높은 비중을 보였으며, 이는 네 팀 중 가장 높은 수치이다. 동시에 Refereeing & VAR도 5.86%로 비교적 높은 편이다. 이러한 패턴은 인천 팬덤이 응원 문화·팬 커뮤니티·경기장 분위기와 같은 사회적 요소, 그리고 판정 이슈에 대해 활발하게 반응하는 문화·이벤트 중심형 관심 구조를 갖고 있음을 보여준다.

마지막으로 울산은 Topic 2(29.02%)와 Topic 3(30.36%)이 가장 높은 비중을 보였으며, 전반적으로 전술·전력 수준과 경기력 평가에 대한 관심이 가장 두드러진 팀이었다. 이는 상위권 팀의 특성과 일치하며, 고질적인 강팀에서 나타나는 경기력 중심의 여론 구조가 재현된 것으로 해석된다.

종합하면, 네 팀의 팬 여론은 공통적으로 경기력 관련 토픽을 중요한 평가 지표로 활용하나, 팀별로 우세한 관심 축은 크게 달랐다. 수원은 외부 요인 중심, 광주는 내부 전술·코칭 중심, 인천은 팬 문화·판정 중심, 울산은 경기력 중심으로 구분되었다. 이러한 차이는 팬덤의 성향, 팀의 시즌 흐름, 구단의 상황적 맥락이 온라인 여론 구조에 반영된 결과로 해석할 수 있다.

4.3 감정 분석 결과

본 연구에서는 2024 시즌 K-리그 4개 팀(광주, 수원, 울산, 인천)을 대상으로 유튜브 댓글에 대해 감정 점수(−2에서 2까지의 연속형 스케일)를 산출하였다. 전체 감정 점수의 분포는 평균 0.089로 약한 긍정을 나타냈으며, 표준편차는 1.14로 댓글 간 감정 편차가 크게 나타났다. 최소값과 최대값은 각각 −2.0과 2.0으로, 모델이 제공한 점수 범위를 고르게 활용한 것으로 확인된다.

TABLE 5 Summary statistics of sentiment score distribution by team

Team	mean	std	min	max	median
Gwangju FC	0.389	1.087	-2.0	2.0	0.6
Suwon FC	-0.262	0.913	-1.9	1.8	-0.4
Ulsan HD	0.074	1.126	-2.0	2.0	0.2
Incheon United	-0.232	1.232	-2.0	2.0	-0.7

각 팀의 감정 점수 분포를 정량적으로 비교하기 위해 평균(mean), 중앙값(median), 표준편차(std), 최소·최댓값을 산출하였다(표 5). 광주는 전체적으로 가장 높은 평균 감정 점수를 나타내었으며, 수원과 인천은 상대적으로 부정적 경향을 보였다. 표준편차는 인천이 가장 높아 팬 반응의 변동성이 큼을 시사한다.

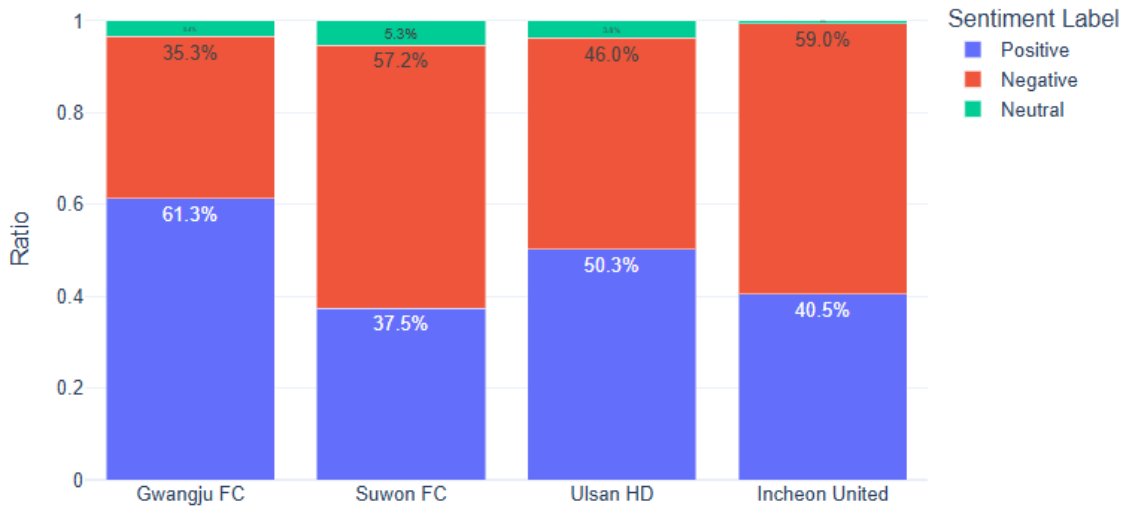

FIGURE 1 Distribution of sentiment labels by team (Stacked Bar Chart)

감정 레이블 분포를 비교한 결과, 광주는 긍정 의견이 가장 우세한 팀, 수원과 인천은 부정 의견이 지배적인 팀, 반면 울산은 긍정과 부정이 비슷한 수준으로 나타나 상대적으로 균형적인 감정 구조를 보였다.

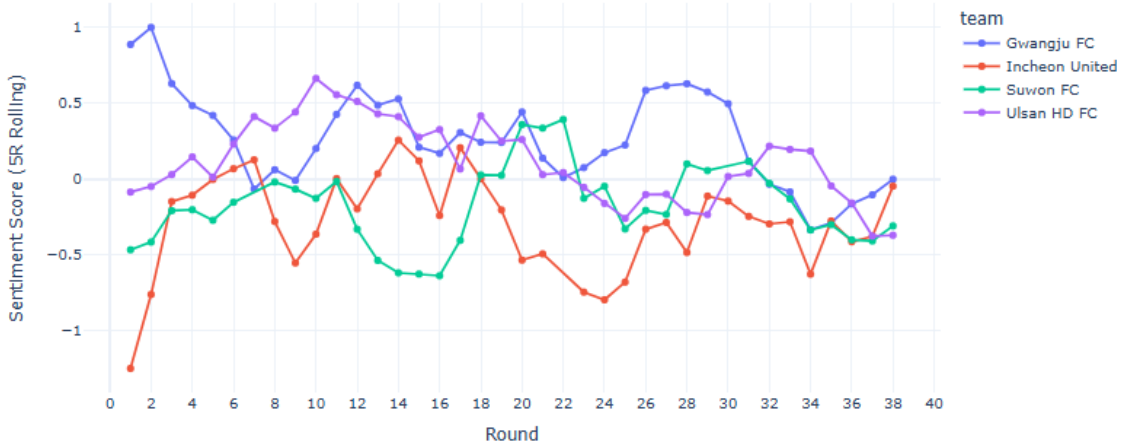

FIGURE 2 Season-long sentiment trend by team (5-round rolling mean)

5라운드 이동평균을 적용한 시즌 감정 흐름을 분석한 결과, 광주 FC와 울산 HD FC는 전반적으로 다른 팀들보다 높은 감정 점수대에서 움직이며 상위권을 형성하는 경향이 나타났다. 반면, 인천 유나이티드는 시즌 전반에 걸쳐 상대적으로 낮은 감정 점수대에 위치하는 모습이 확인되었다. 초반 라운드에서 팀 간 감정 점수의 격차가 가장 크게 나타났으며, 시즌 후반으로 갈수록 그 격차는 상대적으로 작아지는 양상이 관찰되었다.

시즌 초반에 나타나는 팬 감정은 팀에 대한 사전 기대치와 시즌 초반 경기력이 결합된 결과이기 때문에, 이후 시즌 전체에서 나타나는 감정 수준과 높은 관련성을 가질 수 있다. 실제로 초반 라운드의 감정 점수가 높게 형성된 팀은 시즌 중반 이후에도 상대적으로 상위권 감정대

를 유지하는 경향을 보이며, 초반에 낮은 감정 점수로 출발한 팀은 시즌 전체에서도 하위권에 머무르는 패턴이 관찰되었다.

즉, 초기 감정은 단순한 일시적 반응이 아니라, 해당 시즌 동안 팬들이 팀을 어떻게 인식하고 평가할지에 대한 초기 기준점(anchor)으로 작용하며, 이 기준점이 전체 감정 흐름에도 일정 부분 영향을 미친 것으로 해석할 수 있다.

4.4 팀별·토픽별 감정 분석

본 절에서는 팀별 팬 여론의 구조적 차이를 파악하기 위해, 먼저 각 팀에서 30개 이상의 표본이 확보된 토픽만을 대상으로 평균 감정 점수를 비교하였다.

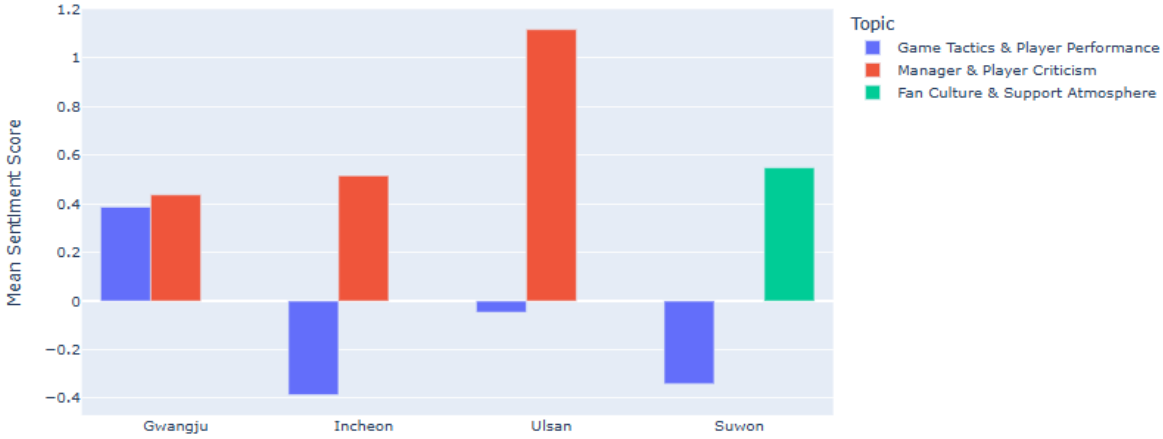

FIGURE 3 Comparison of mean sentiment by team and key topics (Bar Chart)

분석 결과, 동일한 토픽이라도 팀별 감정 반응은 뚜렷한 차이를 보였다. 울산은 Topic 1(Manager & Player Criticism)에서 평균 감정이 약 1.1로 가장 높게 나타나, 감독·선수 평가와 관련된 담론에서 긍정적 평가가 강하게 형성된 것으로 해석된다. 반면 광주는 두 토픽 모두 0.4~0.5 수준의 안정된 긍정적 반응을 보이며, 특정 이슈에 의한 감정 변동이 크지 않은 균형적 팬 여론 구조가 나타났다. 인천은 Topic 2(Game Tactics & player Performance)에서 약 -0.4로 뚜렷한 부정 반응을 보였으나, Topic 1에서는 0.5 내외의 긍정적 감정을 보여 토픽 성격에 따라 감정 방향이 상반되는 패턴을 보였다. 수원은 경기력 관련 토픽(Topic 2)은 -0.35 수준으로 부정적 평가가 주를 이루었지만, 팬 문화·응원 분위기 관련 토픽(Topic 4)에서는 0.55 이상의 긍정적 반응이 나타나, 경기력 평가와 팬 커뮤니티 인식이 독립적으로 작동하는 양상이 확인되었다. 이러한 결과는 동일한 리그 환경에서도 팀 성과·전술적 맥락·팬 커뮤니티 문화 등 다양한 요인에 따라 감정 구조가 다층적으로 형성된다는 점을 시사한다.

이후, 시즌 내 팬 감정의 시간적 변화를 파악하기 위해 각 팀 데이터를 네 개의 시즌 구간으로 분할하여 시계열 분석을 실시하였다. 그러나 일부 팀에서는 특정 토픽의 구간별 표본 수가 매우 적어(1~5개 수준) 평균선이 왜곡되거나 신뢰구간이 형성되지 않는 문제가 확인되었다. 이에 따라 팀 × 구간 최소 표본 수 기준(30개 이상)을 충족한 토픽만 포함하는 방식으로 데이터셋을 재구성하였다. ‘Gwangju, Incheon, Ulsan → Topic 1 & Topic 2 포함, Suwon → Topic 2만 포함’ 구조로 시계열 분석을 진행하였다.

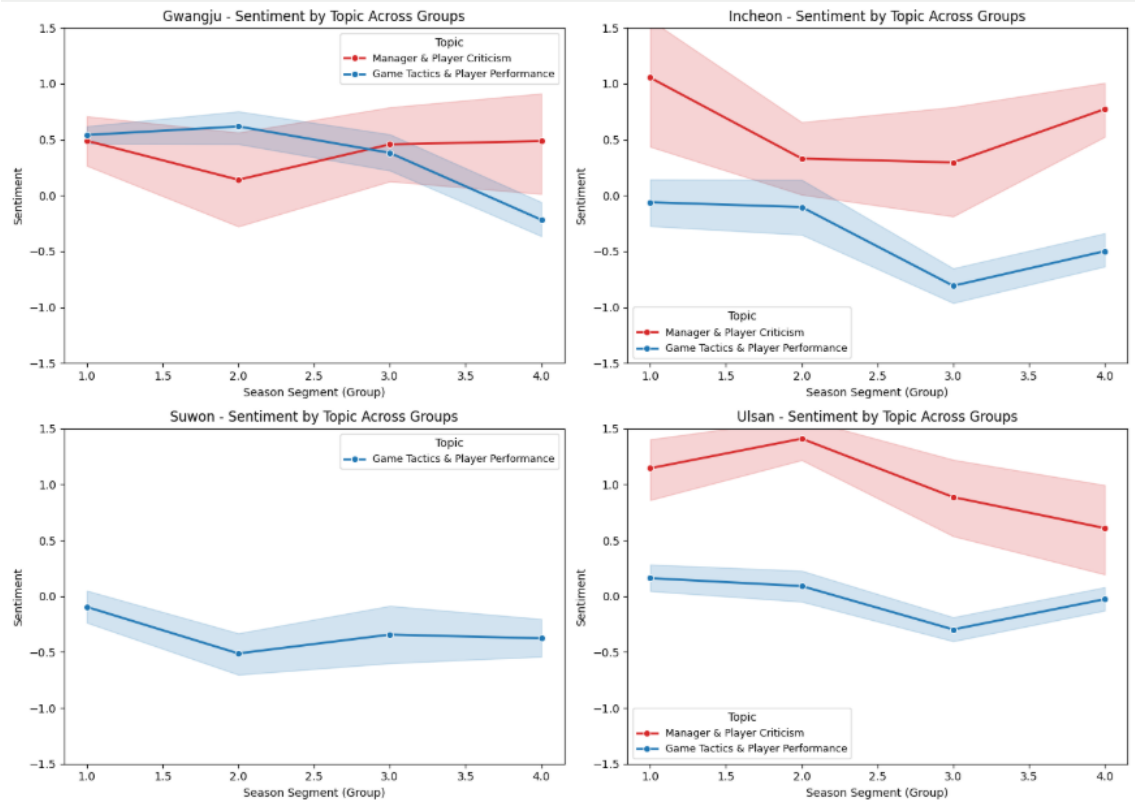

FIGURE 4 Season-long sentiment trend by team (4-segment trajectory)

분석 결과, Topic 1은 전체적으로 변동 폭이 크고 구간별 기복이 존재하는 패턴을 보였다. 이는 비판 관련 담론이 경기 결과, 오심, 선수 이탈 등 이벤트성 이슈에 민감하게 반응한다는 특성과 부합한다. 반면 Topic 2는 네 팀 모두에서 상대적으로 안정적인 흐름을 보이면서도, 시즌 후반으로 갈수록 점진적으로 부정 평가로 이동하는 공통 경향이 확인되었다. 이는 기대 대비 경기력이 만족스럽지 않을 때 누적된 실망이 후기 구간에서 감정 톤을 낮추는 전형적 팬 반응 패턴으로 해석할 수 있다.

또한 Topic 1의 신뢰구간이 Topic 2보다 넓게 나타난 것은, Topic 1에서는 평가 편차가 더 크고 감정 반응이 더 불안정한 반면, Topic 2는 팀 간/구간 간 비교적 일관된 기준에서 이루어지는 특성을 반영한다.

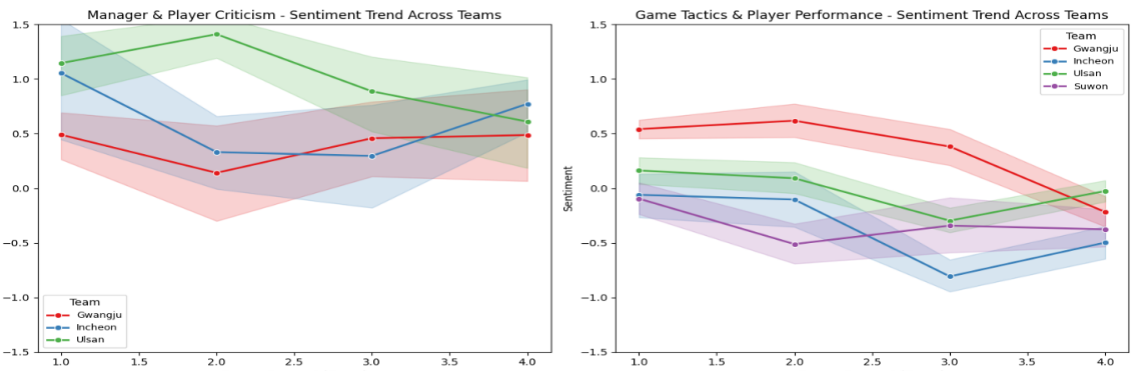

FIGURE 5 Topic-wise sentiment trend across teams (4-segment trajectory)

토픽별 시계열 비교 그래프를 통해 네 팀의 감정 변화 양상을 종합적으로 살펴본 결과, 팀 간 감정 추세는 크게 독립적으로 움직이기보다는, 시즌 구간별로 유사한 범위 내에서 변동하는 것이 확인되었다. 신뢰구간의 폭 역시 팀 간 큰 차이를 보이지 않아, 특정팀이 특정 토픽에서 감정 분산이 특별히 크거나 작은 패턴은 나타나지 않았다.

Topic 1에서는 Gwangju·Incheon·Ulsan 모두 초반 다소 높은 평가 → 중반 하락 → 마지막 구간 회복이라는 유사한 구조를 보였으며, 수원의 경우 표본 부족으로 해석이 어렵다. Topic 2에서는 네 팀 모두 중반부 감정 점수 하락 → 마지막 구간에서 소폭 회복이라는 공통 흐름을 나타냈으며, 이는 앞선 전체적 패턴과 일관된다.

결과적으로, 시즌 중 발생한 주요 흐름에 대한 팬 여론은 네 팀 모두 비교적 유사한 감정적 반응을 공유한 것으로 해석되며, 특정팀만 독립적으로 극단적 상승·하락 흐름을 보이는 패턴은 관찰되지 않았다.

4.5 토픽-감정-경기력의 통합 구조 해석

본 연구는 2024 K리그 네 개 구단(울산, 수원, 광주, 인천)을 대상으로, 유튜브 하이라이트 댓글에서 추출한 팬 여론 감정과 실제 경기력(PCA 기반 지표) 간의 관계를 비교 분석하였다. 분석 결과, 팬들의 감정구조는 단순히 승패나 경기력의 절대적 수준에 의해 결정되는 것이 아니라, 팀별 전술적 특성, 시즌 성적, 팬덤의 기대치, 역사적 맥락이 복합적으로 작용하는 고유한 반응 패턴을 가지고 있음이 확인되었다. 즉, 동일한 경기력 지표 변화라도 팀에 따라 팬 감정은 전혀 다른 방향으로 움직였으며, 이는 팬 여론이 팀 마다의 특성에 기반한다는 것을 보여준다.

특히 리그 1위 울산은 경기력 지표가 상승하면 긍정 여론이 함께 증가하는 강팀 특성에 맞게 안정적이고 일관적인 구조를 나타내는 반면, 최하위권 인천은 경기력이 부분적으로 개선되어도 여론이 쉽게 호전되지 않는 패턴을 보였다. 중위권 수원은 경기 효율성에 민감하게 반응하는 성과 중심이며 기복이 많이 있는 특징을 갖고 있으며, 광주는 이정효 감독 체제 이후 형성된 전술적 신뢰로 인해 경기력이 좋아질수록 기대치가 오히려 높아져 개인 선수에 대한 비판이 유지되는 특징이 나타났다. 이러한 차이는 팬 감정이 단순한 긍정과 부정의 문제가 아니라, 각 팀이 가진 전술적 방향성, 팀의 서사, 성적 등에 따라 다층적으로 형성된다는 점을 실증적으로 보여준다.

TABLE 6 Correlation between Fan Sentiment Topics and PCA-Based Performance Indicators

Team	Topic	Possession/ build-up	Efficiency	Defensive stability
Gwangju	1. Manager & Player Critism	-0.7445	-0.5905	0.3906
	2. Game Tactics & Player Performance	0.9395	0.1662	-0.6664
	3. Scheduling & External Factors	–	–	–
	4. Fan Culture & Support Atmosphere	–	–	–
Suwon	1. Manager & Player Critism	0.6835	0.5809	-0.3055
	2. Game Tactics & Player Performance	-0.3207	0.7388	-0.1937
	3. Scheduling & External Factors	–	–	–
	4. Fan Culture & Support Atmosphere	-0.3095	-0.1876	-0.9829
Ulsan	1. Manager & Player Critism	0.9540	-0.4253	-0.0940
	2. Game Tactics & Player Performance	0.4092	0.4993	0.7904
	3. Scheduling & External Factors	0.3238	0.6663	0.6836
	4. Fan Culture & Support Atmosphere	–	–	–
Incheon	1. Manager & Player Critism	-0.6165	0.1466	0.5203
	2. Game Tactics & Player Performance	-0.2368	-0.7974	-0.5009
	3. Scheduling & External Factors	0.7502	0.4228	0.2042
	4. Fan Culture & Support Atmosphere	–	–	–

5. 결론

본 연구는 2024시즌 K리그 일부 구단을 대상으로, 유튜브 댓글 기반 팬 감정과 PCA를 통해 요약한 경기력 지표 간의 상관 구조를 분석하였다. 텍스트 기반 여론 자료와 정량적 경기 지표를 결합함으로써, 팬 감정이 경기력 변화와 어떤 방식으로 연계되고 분화되는지를 실증적으로 탐색했다는 점에서 의의를 갖는다. 분석 결과, 팬 감정은 경기력 지표의 증감과 일정 수준의 관련성을 보였으나 그 관계의 형태는 팀의 성적 흐름, 전술적 특징, 팬덤의 기대 수준 등 맥락적 요인에 따라 상이하게 나타났다. 이러한 결과는 팬 감정이 경기력의 단순한 부산물이 아니라 팀 고유의 상황과 시즌 내 서사적 맥락을 반영해 형성되는 독립적인 평가 구조임을 시사하며, 동일한 경기력 변화에도 팀별 팬덤이 이를 해석하고 반응하는 방식이 서로 다르다는 점을 확인하게 했다.

BERTopic 기반 토픽 분석 역시 팬 감정이 단일 차원이 아니라 감독·선수 비판, 전술·퍼포먼스 평가, 팬 문화 등 서로 다른 담론 축을 중심으로 다층적 구조를 형성하고 있음을 보여주었다. 감독·선수 비판 토픽은 경기 결과나 사건에 크게 영향을 받아 변동 폭이 컸고, 전술·퍼포먼스 관련 감정은 비교적 안정적인 흐름을 유지하면서도 시즌 후반에 부정성이 증가하는 경향이 나타났다. 네 팀 모두에서 시즌 중반 감정 하락 후 후반부 완만한 회복이라는 공통 패턴이 확인된 점은, 팬 감정이 개별 팀의 경기력뿐 아니라 리그 일정과 시즌 피로도, 외부 이슈 등 보다 광범위한 요소들을 반영하는 집단적 정서 흐름을 포함하고 있음을 시사한다. 이러한 결과는 유튜브 댓글 기반 감정 자료가 팀 수준을 넘어 리그 차원의 정서적 동학을 이해하는 데도 활용할 수 있는 의미 있는 데이터임을 보여준다.

다만, 본 연구의 통계적 결과는 데이터 수집 과정에서의 제약으로 인해 해석에 주의가 필요하다. 당초보다 정교한 분석을 위해 대규모 데이터 확보 및 크롤링을 다 각도로 시도하였으나, 플랫폼의 기술적 정책 변화와 수집 환경의 제약으로 인해 분석 범위를 유튜브 하이라이트 댓글로 한정하게 되었다. 이 과정에서 라운드별 데이터 희소성 문제를 해결하기 위해 도입한 구간 통합(Blocking) 방식은 결과적으로 상관분석에 사용된 표본 수(n)를 축소시켜, 일부 지표에서 상관계수가 과대 계측되거나 통계적 유의성(p-value)을 확보하는 데 한계를 보였다. 실제로 실시한 OLS 회귀분석에서 R^2가 낮고 선형회귀의 기본 가정이 충족되지 않은 점은 이러한 데이터의 비정규성과 표본 크기의 한계에서 기인한 것으로 판단된다. 또한 유튜브 단일 플랫폼에 의존한 점과 외생 변수를 완벽히 통제하지 못한 점 등은 결과 해석의 일반화 가능성을 제한한다.

그럼에도 본 연구는 팬 감정이 경기력의 단순 반영물이 아니라, 팀의 맥락·팬덤 문화·담론 구조와 결합해 독자적인 패턴을 형성하는 능동적 평가 체계임을 실증적으로 보여주었다는 점에서 의미가 크다. 향후 연구에서는 데이터 수집 파이프라인을 고도화하여 트위터·인스타그램·팬카페 등 다양한 플랫폼의 데이터를 대량으로 결합하고, VAR·Granger 인과성 검정 등 더 적합한 방법론을 적용하여 팬 감정-경기력 관계의 구조적 특성을 심층적으로 규명할 필요가 있다. 또한 팀의 역사·기대 수준·조직 특성 등 외생 변수를 통합한 구조적 모형 개발을 통해, 스포츠 데이터 분석에서 팬 감정이 갖는 설명력을 보다 정교하게 확장할 수 있을 것이다.

Reference

Yu, R., & Wang, Q. (2015). World Cup 2014 in the Twitter world: A big data analysis of sentiments in U.S. sports fans' tweets. Computers in Human Behavior, 48, 392-400.

Schumaker, R. P., & Jarmoszko, A. T. (2016). Predicting wins and spread in the Premier League using a sentiment analysis of Twitter. Decision Support Systems, 88, 76-84.

Kang, M. S. (2024). Sentiment analysis of British media coverage of Son Heung-min using text mining. Journal of Holistic Convergence Education, 28(3), 97-111.

Ortu, M., & Mola, F. (2025). The game beyond the field: On football players' performance through social media, sentiment and topic analysis. Computational Statistics, 40(4), 2085-2108.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003).
Latent Dirichlet Allocation. Journal of Machine Learning Research, 3, 993-1022.

Mimno, D., Wallach, H., Talley, E., Leenders, M., & McCallum, A. (2014).
Optimizing semantic coherence in topic models. EMNLP.

Grootendorst, M. (2022).
BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794.

McInnes, L., Healy, J., & Astels, S. (2017).
hdbscan: Hierarchical density based clustering. Journal of Open Source Software, 2(11), 205.

Liu, B. (2012). Sentiment analysis and opinion mining. Morgan & Claypool.

Brown, T. B., et al. (2020). Language models are few-shot learners. Advances in Neural Information Processing Systems, 33, 1877-1901.

Zhao, W. X., et al. (2023). A survey of large language models. arXiv preprint arXiv:2303.18223

Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: A review and recent developments. Philosophical Transactions of the Royal Society A, 374(2065), 20150202.

Jolliffe, I. T. (2002). Principal Component Analysis (2nd ed.). Springer.

Barron, D., Ball, G., Robins, M., & Sunderland, C. (2018). Artificial neural networks and principal component analysis identify predictors of success in professional soccer. Journal of Sports Sciences, 36(18), 1-9.

Rein, R., & Memmert, D. (2016). Big data and tactical analysis in elite soccer: Future challenges and opportunities for sports science. SpringerPlus, 5, 1410.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer.

van Atteveldt, W., Trilling, D., Arcila, C., & Calderón, C. (2021). Computational analysis of communication content. Communication Methods and Measures, 15(2), 95-112.

Fernández-Navarro, J., Fradua, L., Zubillaga, A., & McRobert, A. (2018). Attacking and defensive styles of play in soccer. Journal of Sports Sciences, 36(17), 1-10.

Quantitative Analysis of the Correlation between Fan Sentiment and Match Performance in K-League: A BERTopic and PCA Approach

Minseo Kwak · Seungah Yoon · Heeseok Choi Department of Big Data Convergence, Chonnam National University

Abstract

In the modern sports industry, the interaction between team performance and fan response has become a crucial metric for club management and communication strategies. This study investigates the correlation structure between online fan sentiment and objective match performance indicators for K-League 1 clubs during the 2024 season. For the analysis, YouTube match highlight comments were collected and filtered based on length to ensure data quality. The qualitative fan discourse was quantified using BERTopic for topic modeling and a Large Language Model (LLM) for generating continuous sentiment scores. Simultaneously, high-dimensional performance data (73 indicators) were reduced to three primary axes—Possession/Build-up (PC1), Efficiency (PC2), and Defensive Stability (PC3)—using Principal Component Analysis (PCA). Pearson correlation analysis was conducted across four seasonal blocks to examine the temporal relationship between sentiment and performance. The results indicate that while fan sentiment is partially linked to performance metrics, the strength and direction of this correlation vary significantly depending on the team's context, such as league ranking and tactical narratives. Notably, in lower-ranked teams, improved performance metrics did not immediately translate into positive sentiment, suggesting that fan opinion operates as an independent evaluation structure influenced by accumulated expectations and seasonal narratives.

Keywords: K-League, Fan Sentiment, Match Performance, BERTopic, PCA, Natural Language Processing, LLM.